# **Tubes AI Final**

November 20, 2017

# 1 Tugas Besar IF3170 Inteligensia Buatan 2017/2018

## 1.1 Aplikasi Web Prediksi Income Per Tahun Tahap 1 : Eksperimen

Anggota : 1. Dewita Sonya Tarabunga - 13515021 2. Helena Suzane Graciella - 13515032 4. Emilia Razak - 13515056 3. Jehian Norman Saviero - 13515139

#### 1.1.1 Analisis Data

Data training yang diberikan merupakan data dari 32561 hasil sensus yang memberikan data-data berupa age, workclass, final weight, education, education number, marital status, occupation, race, sex, capital gain, capital loss, hours per week, dan native country. Terdapat juga data test yang akan digunakan untuk melakukan test hasil pembelajaran.

Analisis yang kami lakukan terhadap data adalah analisis terhadap missing value pada data. Terdapat 3 kolom pada data yang memiliki missing value, yaitu '?' yaitu workclass, occupation, dan native country. Selain itu, semua kolom lain tidak memiliki missing value. Setelah dilihat dari data, semua orang yang memiliki missing value pada occupation hanya memiliki dua kemungkinan nilai workclass, yaitu Never-worked atau missing value. Jelas bahwa jika workclass adalah Never-worked, maka orang tersebut tidak memiliki pekerjaan sehingga value nya kosong. Lalu, jika dilihat dari data yang memiliki missing value di keduanya, hampir 90% dari orang tersebut memiliki gross income <= 50K, maka kami mengasumsikan bahwa orang tersebut pernah bekerja, namun sekarang tidak bekerja sehingga tidak masuk ke kategori manapun dalam workclass. Maka kami mengubah missing value di workclass menjadi Not-worked dan missing value di occupation menjadi None.

Satu kolom lagi yang memiliki missing value adalah native country, namun native country merupakan data categorical sehingga tidak masuk akal jika diganti dengan data mean atau median, begitu pula data modus juga kurang cocok untuk menggantikan missing value. Maka kami menganggap missing value sebagai negara lain di luar daftar, atau Other.

Setelah analisis, kami akan melakukan eksperimen dengan akurasi menjadi ukuran kinerja. Kami akan memilih algoritma dengan akurasi terbaik untuk melakukan full traning dan menghasilkan model untuk kemudian digunakan dalam memrediksi data

#### 1.1.2 Eksperimen: 10-Cross Fold Validation

#### Import library yang dibutuhkan

```
In [2]: import pandas as pd
    import numpy as np
```

```
from sklearn import preprocessing
from sklearn import tree
from sklearn.metrics import accuracy_score
from sklearn.metrics import confusion_matrix
from sklearn.model_selection import train_test_split
from sklearn.naive_bayes import GaussianNB
from sklearn.neighbors import KNeighborsClassifier
from sklearn.neural_network import MLPClassifier
from sklearn.model_selection import cross_val_score
from sklearn.model_selection import KFold
from sklearn.externals import joblib
```

#### Membaca data training dari file eksternal

```
In [3]: data = pd.read_csv('CencusIncome.data.txt')
        print(data.head())
        workclass fnlwgt
                                 edu
                                      edunum
                                                         marital occupation \
   age
0
                    51795
                             HS-grad
                                                        Divorced
                                                                       None
   42 Not-worked
       Not-worked 251572
                             HS-grad
                                                                       None
1
   60
                                           9
                                                         Widowed
   28 Not-worked 201844
                             HS-grad
                                           9
                                                        Separated
                                                                       None
3
   28 Not-worked 196630 Assoc-voc
                                                        Separated
                                                                       None
                                          11
       Not-worked 150264 Doctorate
4
                                          16
                                             Married-civ-spouse
                                                                       None
   relationship
                 race
                                gain
                                      loss
                                           hours
                                                          native
                            sex
                                                                  gross
0
      Unmarried Black Female
                                               32
                                                  United-States
                                                                  <=50K
  Not-in-family White
                          Male
                                          0
                                               35
                                                          Poland <=50K
1
2
      Unmarried White Female
                                               40
                                                          Mexico <=50K
3
      Unmarried White Female
                                         0
                                               40
                                                          Mexico <=50K
                                   0
4
        Husband White
                          Male
                                   0
                                         0
                                               20
                                                          Canada
                                                                  >50K
```

### Melakukan encoding pada data categorical

```
In [4]: # Diqunakan OneHotEncoder pada data categorical selain gross income
        for column in data.columns.values:
            if (data.dtypes[column] == object and column != 'gross'):
                enc = pd.get_dummies(data[column])
                data = data.drop(column, axis=1)
                data = data.join(enc)
        # Digunakan LabelEncoder pada data gross karena kolom tersebut merupakan target
        le = preprocessing.LabelEncoder()
        le.fit(['<=50K', '>50K'])
        enc = le.transform(data['gross'])
        data['gross'] = enc
        print(data.head())
                edunum gain loss hours
                                          gross Federal-gov Local-gov \
   age
       fnlwgt
   42
         51795
                                 0
                                       32
                                               0
                                                                       0
                                                            0
```

```
60
         251572
                        9
                              0
                                     0
                                            35
                                                     0
                                                                    0
                                                                                 0
1
2
         201844
                        9
                               0
                                     0
                                            40
                                                      0
                                                                                 0
    28
                                                                    0
                                                                                 0
3
    28
        196630
                       11
                               0
                                     0
                                            40
                                                      0
                                                                    0
4
    67
        150264
                       16
                              0
                                     0
                                            20
                                                      1
                                                                    0
                                                                                 0
   Never-worked
                                            Puerto-Rico
                                                           Scotland South
                                                                              Taiwan \
                                 Portugal
                       . . .
0
                0
                                                        0
                                                                   0
                                                                           0
                       . . .
1
                0
                                         0
                                                        0
                                                                   0
                                                                           0
                                                                                    0
2
                0
                                         0
                                                        0
                                                                   0
                                                                           0
                                                                                    0
3
                                                                                    0
                0
                                         0
                                                        0
                                                                   0
                                                                           0
4
                                         0
                                                        0
                                                                   0
                                                                           0
                                                                                    0
                0
   Thailand
              Trinadad&Tobago United-States
                                                   Vietnam
                                                             Yugoslavia
0
           0
                               0
                                                1
                                                          0
                                                                        0
           0
                                                0
                                                                        0
1
                               0
                                                          0
           0
                               0
                                                0
                                                          0
                                                                        0
3
           0
                               0
                                                0
                                                          0
                                                                        0
```

[5 rows x 109 columns]

#### Melakukan split antara data dan target untuk difit

### **Import Confusion Matrix**

[[2331 127]

In [6]: from sklearn.metrics import confusion\_matrix

#### Melakukan eksperimen dengan Naive Bayes

```
[ 537 261]]
0.792383292383
[[2353 122]
[ 554 227]]
0.789004914005
[[2327 130]
[ 557 242]]
0.777641277641
[[2277 148]
 [ 576 255]]
0.785933660934
[[2322 133]
 [ 564 237]]
0.815724815725
[[2406 112]
 [ 488 250]]
0.793304668305
[[2344 116]
 [ 557 239]]
0.808046683047
[[2382 112]
 [ 513 249]]
0.788697788698
[[2327 129]
 [ 559 241]]
```

#### Melakukan ekperimen dengan Decision Tree Classifier

```
In [8]: kf = KFold(n_splits=10, shuffle=True)
        tclf = tree.DecisionTreeClassifier(criterion="entropy", max_depth=10)
        for train_index, test_index in kf.split(datatrain):
                X_train, X_test = datatrain.iloc[train_index], datatrain.iloc[test_index]
                Y_train, Y_test = targettrain.iloc[train_index], targettrain.iloc[test_index]
                tclf = tclf.fit(X_train, Y_train)
                pred = tclf.predict(X_test)
                print(accuracy_score(Y_test, pred))
                print(confusion_matrix(Y_test, pred, labels=[0,1]))
0.849247774025
[[2357 138]
 [ 353 409]]
0.865171990172
[[2336 128]
 [ 311 481]]
0.851658476658
[[2331 154]
 [ 329 442]]
```

```
0.857493857494
[[2329 127]
[ 337 463]]
0.865786240786
[[2343 105]
 [ 332 476]]
0.855343980344
[[2355 132]
[ 339 430]]
0.855343980344
[[2346 134]
 [ 337 439]]
0.861486486486
[[2362 121]
 [ 330 443]]
0.858415233415
[[2312 124]
[ 337 483]]
0.847972972973
[[2276 210]
[ 285 485]]
```

### Melakukan ekperimen dengan Multilayer Perceptron

```
In [9]: kf = KFold(n_splits=10, shuffle=True)
        nclf = MLPClassifier(alpha=1e-5, hidden_layer_sizes=(20, 20, 20), random_state=1, max_it
        for train_index, test_index in kf.split(datatrain):
                X_train, X_test = datatrain.iloc[train_index], datatrain.iloc[test_index]
                Y_train, Y_test = targettrain.iloc[train_index], targettrain.iloc[test_index]
                nclf = nclf.fit(X_train, Y_train)
                pred = nclf.predict(X_test)
                print(accuracy_score(Y_test, pred))
                print(confusion_matrix(Y_test, pred, labels=[0,1]))
0.795517347252
[[2376
       96]
 [ 570 215]]
0.785626535627
[[2418
       51]
[ 647 140]]
0.791154791155
[[2328 135]
[ 545 248]]
0.681511056511
[[1660 816]
 [ 221 559]]
0.789312039312
```

```
Γ[2431
        37]
 [ 649 139]]
0.803132678133
[[2468
        34]
 [ 607 147]]
0.764434889435
[[2453
         7]
 [ 760
         36]]
0.799754299754
[[2444
        37]
 [ 615 160]]
0.779176904177
[[2447
        18]
 Γ 701
         9011
0.773648648649
ΓΓ2454
        107
 [ 727
         65]]
In [10]: kf = KFold(n_splits=10, shuffle=True)
         knn = KNeighborsClassifier()
         for train_index, test_index in kf.split(datatrain):
                 X_train, X_test = datatrain.iloc[train_index], datatrain.iloc[test_index]
                 Y_train, Y_test = targettrain.iloc[train_index], targettrain.iloc[test_index]
                 knn = knn.fit(X_train, Y_train)
                 pred = knn.predict(X_test)
                 print(accuracy_score(Y_test, pred))
                 print(confusion_matrix(Y_test, pred, labels=[0,1]))
0.773411114523
[[2286 228]
 [ 510 233]]
0.772113022113
[[2245 220]
 [ 522 269]]
0.778255528256
[[2271 201]
 [ 521 263]]
0.766584766585
[[2241 224]
 [ 536 255]]
0.779791154791
[[2263 173]
 [ 544 276]]
0.769041769042
[[2251 205]
 [ 547 253]]
0.777948402948
```

```
[[2292 215]

[ 508 241]]

0.789619164619

[[2310 193]

[ 492 261]]

0.781941031941

[[2281 187]

[ 523 265]]

0.769656019656

[[2246 188]

[ 562 260]]
```

### 1.1.3 Full Training

Kami menggunakan algoritma DecisionTreeClassifier karena algoritma tersebut memiliki akurasi yang paling tinggi.

### **Training**

### Simpan model ke file eksternal

```
In [12]: joblib.dump(tclf, 'model.pkl')
Out[12]: ['model.pkl']
```

#### 1.1.4 Evaluasi Model

#### Load model dari file eksternal

```
In [13]: model = joblib.load('model.pkl')
```

#### Membaca data test dari file eksternal

```
In [14]: test = pd.read_csv('CencusIncome.test.txt')
        print(test.head())
        workclass fnlwgt
                                   edu edunum
                                                          marital \
  age
          Private 226802
                                             7
                                                     Never-married
0
   25
                                  11th
                               HS-grad
1
  38
          Private 89814
                                             9 Married-civ-spouse
                            Assoc-acdm
   28
        Local-gov 336951
                                            12 Married-civ-spouse
3
          Private 160323 Some-college
                                            10 Married-civ-spouse
  44
   58 Not-worked 299831
                               HS-grad
                                             9 Married-civ-spouse
         occupation relationship
                                         sex gain
                                                    loss hours \
                                  race
O Machine-op-inspct
                       Own-child Black Male
```

```
Farming-fishing
                          Husband White Male
                                                        0
                                                               50
1
2
     Protective-serv
                          Husband White Male
                                                               40
                                                   0
                                                         0
3 Machine-op-inspct
                          Husband Black Male
                                               7688
                                                         0
                                                              40
4
               None
                          Husband White Male
                                                  0
                                                         0
                                                              35
         native
                 gross
O United-States
                  <=50K
1 United-States
                 <=50K
2 United-States
                  >50K
3 United-States
                  >50K
4 United-States <=50K
```

### Melakukan encoding pada data categorical

```
In [15]: # Digunakan OneHotEncoder pada data categorical selain gross income
         for column in test.columns.values:
              if (test.dtypes[column] == object and column != 'gross'):
                  enc = pd.get_dummies(test[column])
                  test = test.drop(column, axis=1)
                  test = test.join(enc)
          # Digunakan LabelEncoder pada data gross karena kolom tersebut merupakan target
         le = preprocessing.LabelEncoder()
         le.fit(['<=50K', '>50K'])
         enc = le.transform(test['gross'])
         test['gross'] = enc
         print(test.head())
                 edunum
                                      hours
                                              gross
                                                      Federal-gov
                                                                   Local-gov \
   age
        fnlwgt
                         gain
                                loss
    25
        226802
                      7
                                   0
                                          40
0
                                                   0
                                                                            0
1
    38
        89814
                      9
                             0
                                          50
                                                   0
                                                                0
                                                                            0
2
    28
        336951
                     12
                                   0
                                          40
                                                   1
                                                                0
                                                                            1
3
    44
        160323
                     10
                         7688
                                   0
                                          40
                                                   1
                                                                0
                                                                            0
        299831
                      9
                             0
                                   0
                                          35
                                                   0
                                                                            0
   Never-worked
                               Portugal
                                         Puerto-Rico
                                                        Scotland South
                                                                          Taiwan \
0
               0
                                                     0
                                                               0
                                                                       0
                     . . .
                                                     0
                                                               0
                                                                       0
                                                                                0
1
               0
                                       0
                     . . .
2
               0
                                      0
                                                     0
                                                               0
                                                                       0
                                                                                0
                      . . .
3
               0
                                      0
                                                     0
                                                               0
                                                                       0
                                                                               0
4
                                       0
                                                                                0
   Thailand Trinadad&Tobago United-States
                                                Vietnam
                                                          Yugoslavia
0
          0
                                             1
                                                       0
          0
                             0
                                             1
                                                       0
                                                                    0
1
2
          0
                             0
                                             1
                                                       0
                                                                    0
3
          0
                             0
                                             1
                                                       0
                                                                    0
```

```
[5 rows x 108 columns]
```

**Menambah kolom yang kurang pada data test** Terdapat satu kategori pada native country yang tidak muncul pada data test, yaitu Holand-Netherlands. Akibatnya saat dilakukan OneHotEncoding, kolom tersebut tidak muncul, padahal kolom dari data training dan test harus sama. Maka solusinya adalah menambah kolom Holand-Netherlands yang berisi 0 pada setiap row.

```
In [16]: test['Holand-Netherlands'] = 0
    test = test[data.columns.tolist()]
```

# Melakukan split antara data dan target untuk diprediksi

## Melakukan prediksi